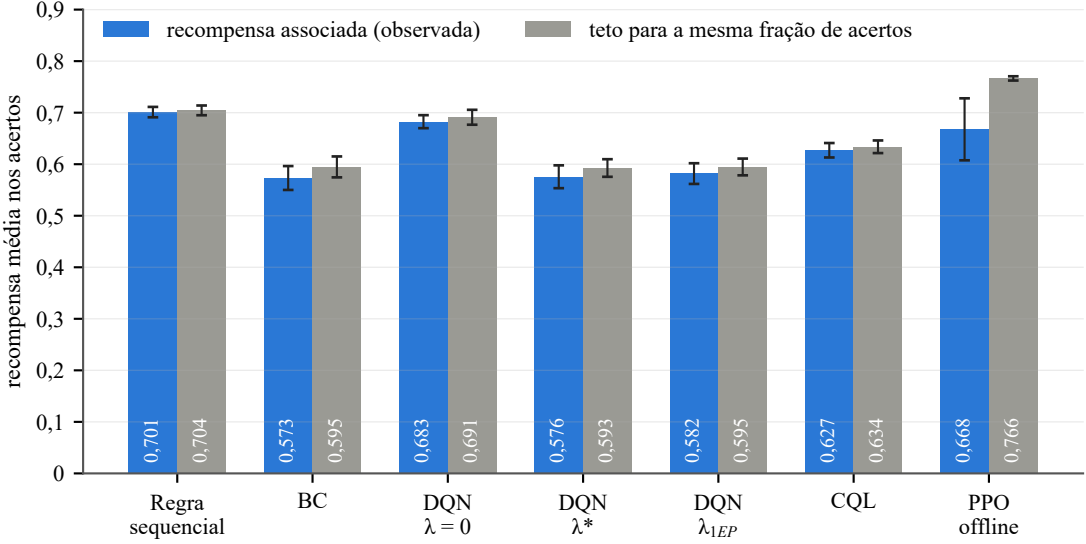
recompensa associada (observada)
teto para a mesma fração de acertos
recompensa média nos acertos
0,9
0,8
0,7
0,6
0,5
0,4
0,3
0,2
0,1
0
0,701
0,704
0,573
0,595
0,683
0,691
0,576
0,593
0,582
0,595
0,627
0,634
0,668
0,766
Regra sequencial
BC
DQN λ = 0
DQN λ*
DQN λ1EP
CQL
PPO offline